


## 기말고사 과제

Image Classification을 위한 Deep Neural Network 구성요소 설명




### 1. Convolution Layer

컨볼루션 레이어는 여러 개의 레이어로 구성되어 있으며, 각 레이어는 서로 다른 학습 과정과 테스트 과정을 거칩니다. 컨볼루션 레이어를 구성하는 필터의 종류는 대략 다음과 같습니다.

- Gaussian filter (average)
- Sharpen convolution (edge finding)
- Laplacian
- Laplacian of Gaussian filter (Gaussian + Laplacian)

컨볼루션 레이어는 매우 다양한 종류의 필터를 단일한 입력값에 대하여 적용하며, 그 결과값을 filter banks 형태로 취합하여 반환합니다. 이러한 filter banks는 다른 컨볼루션 레이어의 입력값으로 활용되기도 합니다.



기존 머신러닝 기법 대비 차이점 / 우수성

|           | Traditional Filters | Convolutional Layers              |
|-----------|---------------------|-----------------------------------|
| 필터의 개수    | 10-30               | 64-1024                           |
| 필터값       | 사용자가 미리 결정          | 학습을 통해 취득                         |
| 필터 출력 목표값 | 필요 없음               | 필요하지만 모름                          |
| 필터 입력     | 입력 이미지              | 입력 이미지 혹은 앞선 Convolution Layer 결과 |

## 2. Activation Function

각각의 Convolution layer와 fully-connected layer가 끝날 때마다 뒷단에 배치되는 간단한 함수 구간으로, 비선형성을 표현하고 해결하기 위하여 존재합니다.

액티베이션 함수는 인간의 뉴런에서 착안된 구성요소로, 특정한 기준값 아래의 값은 전달하지 않고 무시해 버립니다. 이 함수는 모든 레이어의 뒷단에 들어가며, 따라서 하나의 레이어가 끝날 때마다 반복적으로 실행됩니다.

이 함수는 기본적으로 간단한 형태를 가지고 간단한 연산을 실시하지만, 이 작은 task를 레이어마다 반복함으로써 매우 복잡한 비선형성 문제를 해결합니다.


### 기존 머신러닝 기법 대비 차이점 / 우수성

기존 머신러닝 기법으로는 Kernel Trick이 있습니다. 커널 트릭은 데이터 피쳐 차원이 높아질수록 복잡도가 크게 증가한다는 단점을 갖습니다. 반면, 활성화 함수는 함수 형태를 고정한 뒤 동일하게 반복 적용하게 됩니다. 속도가 빠르고, 복잡성이 더해지지 않으며, 단순한 구조가 강점입니다.

한 가지 중요한 점은, 활성화 함수가 컨볼루션 레이어나 풀리 커넥티드 레이어 뒷단마다 들어가지 않는다면, 각 레이어들 간의 선형성이 한 줄로 쭉 이어지게 됩니다. 이는 곧, 수십 개의 컨볼루션 레이어를 통과하더라도 그 결과가 큰 틀에서 단 하나의 컨볼루션 필터를 적용한 값과 크게 달라지지 않게 된다는 뜻입니다. 활성화 함수는 각 레이어가 끝날 때마다 적용되어, 레이어 간의 선형성이 유지되지 않도록 도와줍니다.

## 3. Pooling Layer

각각의 Convolution Layer 사이에 위치하는 레이어입니다. 풀링 레이어는 입력된 이미지 또는 컨볼루션 필터 결과값의 해상도를 낮추는 역할을 수행합니다. 입력된 이미지가 100\*100 해상도일 경우, 적용하는 필터 갯수가 1000개라면 결과값은 100\*100\*1000이 됩니다. 이는 지나치게 계산 부담이 되므로, 풀링 레이어로 해상도를 낮추면 계산 효율화 효과가 있습니다.



풀링 레이어는 다음과 같이 동작합니다.

1. 풀링 레이어에 입력된 어떤 피쳐 결과값들 중 최대값 1개 선택
2. 상대적으로 작은 Resolution 이미지의 저해상도 이미지 1개 값으로 배정
  - a. 4개 픽셀 > 1개 픽셀 축소
  - b. 기존 입력된 이미지보다 해상도 훨씬 낮은 feature 결과로 변환
  - c. 입력된 이미지 크기보다 훨씬 작은 필터 결과값을 얻음

## 기존 머신러닝 기법 대비 차이점 / 우수성

풀링 레이어는 이미지 해상도와 필터 갯수에 따라 크게 증가할 수 있는 피쳐 갯수를 줄임으로써, 계산 효율성을 높임과 동시에 비선형성도 개선(보정)하는 효과를 냅니다.

기존 머신러닝 기법과 비교하면 피쳐 갯수를 줄이는 차원축소 등이 있을 수 있으나, 풀링 레이어의 방법은 핵심적인 정보를 잃지 않은 채 연산량만 줄인다고 말할 수 있습니다.

## 4. Fully-connected Layer

Convolution Layer와 마찬가지로, fully-connected layer 또한 여러 겹의 레이어로 구성되어 있습니다. Fully-connected layer는 다음과 같은 순서로 동작하며, Fully-connected layer의 마지막 레이어는 전체 모델의 마지막 레이어로서 Last Layer라고 불리기도 합니다.

1. 첫 번째 fully-connected layer 입력받음
2. 입력값이 레이어1을 거치면서 변형
3. 변형된 입력값을 두 번째 fully-connected layer로 입력
4. 입력값이 레이어2를 거치면서 변형
5. ...
6. 마지막 fully-connected layer (last layer) 입력
7. 최종 입력된 feature 기반으로 최종 라벨 출력

기본적으로 fully-connected layer는 가장 마지막의 last layer를 제외하고는 linear regressor(선형 회귀 모델)와 동일한 역할을 수행합니다.

## 기존 머신러닝 기법 대비 차이점 / 우수성

Fully-connected layer는 128개에서 2048개까지의 아웃풋을 출력합니다. 입력된 feature에 가중치 행렬  $W$ 를 곱하고, 그러한 가중치 행렬에 대응하여 출력되는 값들 또한 여러 개가 나오는 구조입니다. 간단히 말해, linear regressor 여러 개가 하나로 묶여 있다고 생각할 수 있습니다.

일반적인 linear regressor는 서로 다른  $W$ 를 곱하고, 그것의 합을 예측값으로 출력합니다. 하나의 아웃풋을 갖습니다. linear regressor와 fully-connected layer는 모두 prediction 결과 (목표값)와 비슷하게 출력을 내고자 하는 목표를 갖습니다. 그러나 목표값이 어떤 상황인지 알지 못하기 때문에, fully-connected layer를 hidden feature 또는 latent feature라고 부르기도 합니다.

Linear Classification 모델과 비교해 보면 아래와 같습니다.

| Linear Classification Model               | Fully-connected Layer  |
|---|--|
| 정해진 필터를 적용한 결과값이나 주어진 데이터를 그대로 활용하여 input | 수많은 convolution layer와 fully-connected layer를 통해 여러 번 계산, 정제된 feature를 input |